



TRABAJO FIN DE GRADO

Un modelo robusto para maximizar la propagación de la influencia en redes sociales

Realizado por: Patricia Jiménez Sanabria

Supervisado por: Eduardo Conde Sánchez

FACULTAD DE MATEMÁTICAS
DPTO DE ESTADÍSTICA E INVESTIGACIÓN OPERATIVA

Índice general

Resumen	V
Abstract	VII
Índice de Figuras	X
Tabla de notación	XI
Prólogo	XIII
1. El problema de la propagación de la influencia	2
1.1. Algoritmo de propagación de influencia	2
1.2. Formulación del modelo robusto de propagación de la influencia	5
1.2.1. Relación con el modelo de Bertsimas y Sim	7
Incertidumbre en umbrales de activación y grados de influencia	7
La formulación robusta de Soyster	8
El nuevo enfoque robusto	9
2. Propiedades de la formulación del modelo de propagación	16
2.1. Complejidad del problema	16
2.2. Análisis de sensibilidad	22
3. Reformulación del problema no robusto usando conjuntos de activación	27
3.1. Conjuntos de activación de los nodos de la red	27
3.2. Uso de dualidad lineal para reformular el problema	30
4. Branch-Cut-and-Price para la maximización robusta de influencia	35
4.1. Generación de los conjuntos minimales de activación	36

4.2.	Generación y reemplazo de filas	39
4.3.	Generación de columnas	43
5.	Estudio experimental	47
5.1.	Enlazar <i>RStudio</i> con <i>AMPL IDE</i>	48
5.2.	Códigos <i>RStudio</i>	49
5.2.1.	Instancia de un grafo aleatorio	49
5.2.2.	Resolución exacta del problema (R-IMP)	52
5.2.3.	Algoritmo heurístico	54
5.3.	Códigos <i>AMPL</i>	56
5.3.1.	Problema $RI_{x,\theta,\phi}(\bar{y})$: <code>grafo.mod</code>	56
5.3.2.	Problema de cubrimiento maximal: <code>covering.mod</code>	58
5.4.	Comparación con posibles versiones del heurístico	61
5.4.1.	Comparación de heurísticos variando el problema <code>covering.mod</code>	62
5.4.2.	Comparación de heurísticos variando el factor de reducción	67
5.4.3.	Comparación del mejor heurístico con el exacto	73
	Conclusiones	78
A.	Fundamentos del método de generación de columnas	80
A.1.	Generación de columnas	81
A.2.	Descomposición Dantzig-Wolfe para problemas enteros	83
A.3.	Ejemplo prototipo	85
A.3.1.	Una reformulación equivalente	87
A.3.2.	La relajación lineal del problema maestro	88
B.	Códigos de programación usados en el experimento	91
B.1.	Código de <code>grafo_dirigido_aleatorio</code>	91
B.2.	Código de <code>guardar_grafo_ampl</code>	92
B.3.	Generación de subconjuntos de semillas: <code>todasLasSemillas</code>	95
B.4.	Configuración de <i>AMPL</i> en <i>R</i>	96
B.5.	Generación del archivo de semillas para <i>AMPL</i> : <code>semillas.dat</code>	97

B.6. Construcción del archivo: <code>covering.dat</code>	98
B.7. Resolución del problema de cubrimiento maximal	100
B.8. Evaluación final del conjunto heurístico de semillas	100
Referencias bibliográficas	103

Resumen

Durante este primer cuarto de siglo, la utilización de redes sociales, potenciadas por el auge de Internet, ha permeado prácticamente todos los ámbitos de la interacción humana. Uno de los usos comunes en redes es la transmisión de información y la difusión de la influencia que tienen unos usuarios sobre otros para crear estados de opinión.

Puede tratarse de inclinar a los usuarios frente a una opción de compra o frente a un partido político. Puede tratarse de información veraz o de bulos, concepto que está a la orden del día en noticiarios y periódicos. Lo que se llama estos últimos años *el control del relato* no es más que eso, usar la influencia en redes para difundir una determinada visión de la actualidad política o social.

En el modelo matemático de este proceso suelen utilizarse parámetros que cuantifican umbrales y pesos de influencia. Sin embargo, hay una cuestión de primer orden al respecto, ¿cómo se estiman estos parámetros? No es fácil dar un coeficiente que mida el grado de influencia ejercido por un usuario de la red sobre otro, ni la influencia que debe ser ejercida sobre alguien para que cambie su opinión sobre un determinado hecho u opción. Por esta razón, se están analizando en la literatura reciente modelos en los que estos parámetros se consideran variables o solo parcialmente conocidos.

Por decirlo de alguna manera, cada configuración de parámetros sería una foto fija del comportamiento de la red, un escenario. Bajo este escenario se pueden plantear problemas como el que se considera en este trabajo, ¿qué usuarios deben ser incentivados para transmitir una información o difundir la influencia en una red lo máximo posible? Una vez elegidos estos usuarios, bajo cada escenario de pesos y umbrales, el resultado de difusión será diferente. El modelo de optimización robusta que se planteará en este trabajo, maximiza el número de usuarios a los que

influiremos con garantía, sea cual sea la configuración de parámetros, sea cual sea el escenario bajo el que se produzca la difusión de la información que se quiere transmitir o la influencia que se desea ejercer.

Comenzaremos formulando matemáticamente el modelo, estableciendo claramente las variables del problema y el conjunto de parámetros que consideramos admisible. Lo que se llama el modelo de incertidumbre asumido, en nuestro caso un modelo análogo al que Bertsimas y Sim publicaron en 2004 bajo el elocuente título de *The price of robustness*. En este modelo se admite variación de los parámetros, pero teniendo en cuenta que en la práctica no todo suele variar sustancialmente al mismo tiempo.

El capítulo 3 se dedica al análisis computacional del problema de optimización propuesto. Se establece su carácter NP-completo y se estudia cómo afectan algunas de las características del modelo de incertidumbre a la solución obtenida.

En el siguiente capítulo se exploran diferentes formulaciones del problema en base a los denominados *conjuntos minimales de activación*. Usando estos conjuntos, Nannicini *et al.* [8] han propuesto un algoritmo exacto en 2020 del tipo Branch-Cut-and-Price. Este artículo es el que se ha usado de base en toda la memoria que termina con el desarrollo de un experimento numérico en el que se prueba un heurístico de elaboración propia.

En la parte final del trabajo se incluyen apéndices que recogen algunos elementos conceptuales sobre el método de generación de columnas y códigos de programación empleados en el estudio experimental.

Abstract

During this first quarter of the century, the use of social networks, boosted by the rise of the Internet, has permeated practically every area of human interaction. One common use of social networks is the transmission of information and the dissemination of the influence users exert on one another to shape public opinion.

This influence can be directed toward swaying users' choices regarding a product or a political party. It may involve truthful information or misinformation—fake news, a concept that is frequently featured in news broadcasts and newspapers. What has been referred to in recent years as *narrative control* is nothing more than this: using influence on social media to spread a particular vision of current political or social affairs.

In the mathematical modeling of this process, parameters are typically used to quantify influence thresholds and weights. However, a key question arises: how are these parameters estimated? It is not easy to assign a coefficient that measures the degree of influence a user exerts over another, or the amount of influence needed to change someone's opinion on a given fact or option. For this reason, recent literature has been exploring models where these parameters are treated as variables or only partially known.

Put another way, each configuration of parameters represents a snapshot of the network's behavior—a scenario. Under each scenario, one can consider problems such as the one addressed in this work: Which users should be incentivized to transmit information or spread influence as widely as possible in the network? Once these users are selected, the diffusion outcome will vary depending on the scenario of thresholds and influence weights. The robust optimization model proposed in this study aims to maximize the number of users we can influence with certainty, regardless of the parameter configuration—that is, regardless of the scenario under which the

intended information or influence is disseminated.

We begin by mathematically formulating the model, clearly defining the problem variables and the set of admissible parameters. This corresponds to what is called the assumed uncertainty model, in our case analogous to the one proposed by Bertsimas and Sim in 2004 under the telling title *The Price of Robustness*. In this model, parameter variation is allowed, but not everything can vary significantly at the same time.

Chapter 3 is devoted to the computational analysis of the proposed optimization problem. We establish its NP-completeness and study how certain characteristics of the uncertainty model affect the solution obtained.

In the following chapter, different formulations of the problem are explored based on so-called *minimal activation sets*. Using these sets, Nannicini *et al.* [8] proposed an exact Branch-Cut-and-Price algorithm in 2020. This article has served as the basis for the entire Bachelor Final Project, which concludes with the development of a numerical experiment testing a custom-designed heuristic.

The final part of the work includes appendices containing some conceptual elements on the column generation method and the programming code used in the experimental study.

Prólogo

Hoy en día, el avance de la digitalización, el crecimiento de las redes sociales y el desarrollo de la inteligencia artificial han hecho que la propagación de la información —o de la desinformación— alcance una escala y velocidad sorprendente (véase p.e. [6]). En especial, el fenómeno de las “fake news” se ha vuelto más frecuente y es capaz de engañar a la sociedad, ya que muchos algoritmos de recomendación priorizan el contenido viral frente al veraz. A esto se suma la creación de bots sociales, programados para simular actividad humana y amplificar mensajes específicos, lo que convierte esta dinámica en un fenómeno cada vez más preocupante y potencialmente peligroso.

Aunque los bulos parecen ser un problema moderno, en realidad, desde la antigüedad se han utilizado como herramientas de poder, control e influencia. Un claro ejemplo de este fenómeno histórico es la conocida como *Leyenda Negra*, una narrativa profundamente negativa sobre el Imperio Español que se extendió por Europa a partir del siglo XVI. Esta imagen distorsionada, promovida por potencias rivales como Inglaterra y los Países Bajos, presentaba a España como un imperio cruel, fanático y opresor, especialmente en su trato a los pueblos indígenas en América. La *Leyenda Negra* fue amplificada y manipulada con fines propagandísticos, afectando la imagen internacional de España.

A pesar de que la difusión de ideas o rumores ha sido una constante a lo largo de la historia de la humanidad, en este trabajo nos centraremos en el entorno de las redes sociales. Esto se debe a que, a diferencia de los medios tradicionales, las redes sociales no solo permiten una propagación más rápida, masiva y global, sino que además ofrecen una estructura observable para medir su alcance e impacto.

Por esta razón, este trabajo se centra en el estudio del problema de la maximización de la

propagación de la influencia en redes sociales, con el objetivo de desarrollar un modelo robusto y eficaz que permita seleccionar un conjunto óptimo de nodos iniciales, donde se origina el mensaje que se desea transmitir, capaces de generar la mayor difusión posible. Este problema, de gran relevancia práctica y teórica, combina elementos de teoría de grafos y diseño algorítmico, y tiene aplicaciones como marketing digital, campañas de concienciación social, manipulación política, propaganda electoral, etc.

Comenzaremos describiendo los elementos fundamentales del problema de optimización, la estructura de la red y los indicadores del grado de influencia de un usuario y de cómo activa (o no) a otros usuarios con la información difundida.

Una vez introducidos los parámetros del problema observaremos que la dificultad en estimarlos justifica el uso de un modelo de optimización robusta. Se propone dicho modelo y se relaciona con el modelo de Bertsimas y Sim (2004) [1].

En el siguiente capítulo se estudia la complejidad teórica que tiene el problema de optimización. Se verá que es un problema NP-completo lo que motiva el análisis de métodos heurísticos de resolución como complemento a los métodos exactos.

En el capítulo 4 se discuten diferentes variaciones en la formulación del problema en base a los denominados conjuntos minimales de activación que serán usados en el siguiente capítulo en la construcción de un algoritmo Branch-Cut and Price para resolver el problema de forma exacta. Este algoritmo fue propuesto por Nannicini *et al.* (2020) [8] pero, como los propios autores reconocen, su implementación computacional es bastante complicada. De hecho, en su artículo, estos autores proponen una variante heurística del algoritmo exacto que resulta ser más operativa.

El último capítulo del trabajo se dedica a la realización de un estudio experimental en el que se hará nuestra propia propuesta de un algoritmo heurístico, en base a la resolución de un problema de cubrimiento por un conjunto óptimo de semillas de la red.